

1_Время запроса, Объем сканирования, Период поиска, Тип операции поиска (Стенд ST)

Исходные данные

Стенд: <https://platform-st.opsmon.sbt/da-dp02-om-st-mind-01/>

Источник: БД ARQS

Глубина периода выборки: от (19.09.2026 - 9 мес) до 19.09.2026.

Получены все запросы со статусом FINISHED

Запрос:



2_scan_speed_file_category

Сырые данные:



raw_data.csv

Структура выборки

Расчёт скорости сканирования индексов с категоризацией запросов. **Правило скорости:** `seconds_per_gb = время выполнения (сек) / объём данных (ГБ)`.

Источник: `archive_queries` + `archive_query_file_conditions`

Фильтр: `status = 'FINISHED'`, `volume_bytes >= 1`, за последние **9 месяцев**

Классификация по `final_sql_query` с вычищенными системными условиями `__time >= / <=` (добавляются движком во все запросы и засоряют детект операторов)

Вывод: до 100 000 строк, по убыванию `seconds_per_gb`

Фактическая выгрузка: `raw_data/raw_data.csv` (8 840 строк)

#	Поле	Тип	Описани
1	archive_query_id	uuid (string)	Идентиф
2	name	text	Имя запр
3	created_ts	timestamp	Момент с
4	final_status_ts	timestamp	Момент з
5	search_from	timestamp	Начало (__time :
6	search_to	timestamp	Конец вр <=)
7	volume_bytes	numeric	Объём да
8	volume_mb	numeric	Объём в
9	volume_gb	numeric	Объём в
10	duration_sec	numeric	Время вы
11	duration_min	numeric	Время вы
12	seconds_per_gb	numeric	Скорости
13	minutes_per_gb	numeric	Минут на
14	seconds_per_mb	numeric	Секунд на
15	minutes_per_mb	numeric	Минут на
16	like_count	integer	Количест (без RLIKE, LIKE, и IL
17	query_category	text	Категори ниже)
18	duration_group	text	Глубина search_fr
19	file_used	text	Были ли ф
20	file_conditions_count	integer	Число archive_ нет)

Справочник query_category

Классификация идёт по sql_wo_time (final_sql_query без __time -условий), порядок проверок — как в CASE WHEN (первое совпавшее правило побеждает):

Значение	Правило
1_SYSTEM_METAMODEL	sql_wo_time ~* '^SELECT\s+DISTINCT\s+["]]?module["]?\s*,\s*["]?metamodelVersion["]?'
2_RLIKE	position('RLIKE' in upper(sql_wo_time)) > 0
3_LIKE_FULLTEXT	like_count >= 10
4_LIKE_MULTI	like_count >= 2 (и < 10)
5_LIKE_SINGLE	like_count = 1
6_IN	sql_wo_time ~* '\bIN\s*\('
7_EQ	`sql_wo_time ~* '(<=>
8_NO_FILTER	иначе

Распределение в выборке (8 840 строк): 8_NO_FILTER — 5 668 (64%), 3_LIKE_FULLTEXT — 1 846 (21%), 5_LIKE_SINGLE — 757, 7_EQ — 316, 4_LIKE_MULTI — 142, 1_SYSTEM_METAMODEL — 109, 2_RLIKE — 2.

Справочник duration_group

Значение	Правило (search_to - search_from
1_month	≤ 31 дня
2_quarter	≤ 92 дней
3_halfyear	≤ 183 дней
4_more	6 месяцев
0_unknown	search_from или search_to равны

Справочник file_used

Значение	Правило
A_no_file	file_conditions_count = 0 — file-y
B_with_file	file_conditions_count > 0 — есть y

Цель: Исследовать зависимости Время запроса, Объем сканирования, Период поиска, Тип операции поиска

Проведен разведочный стат анализ с использованием математического пакета стат исследований Python.
Определена модель прогнозирования.

Результаты

Главный вывод

Время выполнения поискового запроса в этой системе **почти не зависит от объёма данных**, а определяется **типом поиска** (полнотекст / регулярка / LIKE / равенство) и **глубиной ретроспективы** (по каким месяцам ищем). Показатель масштаба γ близок к нулю для всех типов, кроме полнотекста — значит, для «обычных» запросов время — примерно **константа** (~1–2 минуты), а полнотекст растёт медленно ($\propto V^{0.27}$).

Формула

$$T = \beta_{\text{тип}} \cdot \delta_{\text{глубина}} \cdot V^{\gamma_{\text{тип}}}$$

где:

- T** — время в секундах;
 - V** — объём данных в ГБ;
 - β** — Базовое время обработки **1 ГБ** данных данного типа поиска (секунды) (таблица ниже);
 - γ** — как сильно время растёт с объёмом (для «обычных» типов ≈ 0);
 - δ** — поправка на глубину ретроспективы (таблица ниже).
- Для всех типов, кроме полнотекста, $\gamma \approx 0$, поэтому $V^\gamma \approx 1$ и формула упрощается до: **$T \approx \beta \times \delta$** .

Коэффициенты (подставить свои значения V и глубину) [↗](#)

Тип поиска	β (сек)	γ
Полнотекст	3666	0.27
Регулярные выражения	79	-0.017
Содержит (LIKE)	122	0.032
Равно / не равно	119	0.026
Глубина ретроспективы	δ (дельта)	
До 1 мес	1.00	
1-3 мес	0.82	
3-6 мес	0.76	
Свыше 6 мес	0.94	

Где:

Коэффициент	Что это	Аналогия
β	Базовое время обработки 1 ГБ данных данного типа поиска (секунды)	«цена одного гигабайта» за данный
γ	Показатель степени: насколько время растёт при увеличении объёма в 2 раза и т.д.	«коэффициент подорожания при ро
δ	Множитель поправки на глубину ретроспективы (за какой период ищем)	«скидка/надбавка за срок поиска»

Почему так устроено: модель $T = \beta \cdot \delta \cdot V^\gamma$ — это *мультипликативная* (степенная) зависимость: полный срок складывается не сложением, а перемножением трёх факторов. β — «сколько стоит сам тип поиска», V^γ — «сколько стоит объём», δ — «сколько стоит глубина ретроспективы». Статистически (ANOVA) значимым оказался именно такой раздельный вклад каждого фактора (взаимодействие тип×объём значимо, $p=8.3e-8$).

Практические следствия:

- $\gamma=0 \rightarrow$ при поиске LIKE/равенством **объём почти не важен**: время $\approx \beta \cdot \delta$.
- β различается в разы (79...3666 сек) $\rightarrow$ **тип поиска — главный фактор времени**.

Готовая таблица: время по типу и объёму

Глубина = «До 1 месяца» (δ = 1). Оценочное время запроса.

Тип поиска	1 МБ	10 МБ	100 МБ
Регулярные выражения	1.5 мин	1.4 мин	1.4 мин
Равно/не равно	1.7 мин	1.8 мин	1.9 мин
Содержит (LIKE)	1.6 мин	1.8 мин	1.9 мин
Полнотекст	9.4 мин	17.5 мин	32.7 мин

Читаем так: полнотекст по 1 ГБ ≈ 1 ч, по 100 МБ ≈ 33 мин; обычный LIKE по любому объёму ≈ 1–2 мин.

Поправка глубины ретроспективы (δ)

Возьмите время из Таблицы 1 (глубина «1 мес») и **умножьте** на δ нужной глубины:

Глубина	δ
До 1 мес	1.00
1–3 мес	0.82
3–6 мес	0.76
Свыше 6 мес	0.94

Полный пример: как посчитать вручную

Задача: *полнотекстовый поиск по 200 МБ данных за 3–6 месяцев.*

- Переведём объём: 200 МБ = 0.2 ГБ → **V = 0.2**.
- Берём β полнотекста = **3666**, γ = **0.27**.
- Берём δ для «3–6 мес» = **0.76**.
- Подставляем: $T = 3666 \times 0.76 \times 0.2^{0.27}$.
- $0.2^{0.27} \approx 0.595 \rightarrow T \approx 3666 \times 0.76 \times 0.595 \approx$ **1660 сек ≈ 28 мин**.

Проверка по модели: *1795 сек = 29.9 мин.*

Кросс-таблица: время по 100 МБ для всех типов и глубин

Тип	До 1 мес	1-3 мес	3-6 мес
Регулярные выражения	1.4 мин	1.1 мин	1.0 мин
Равно/не равно	1.9 мин	1.5 мин	1.4 мин
Содержит (LIKE)	1.9 мин	1.5 мин	1.4 мин
Полнотекст	32.7 мин	26.8 мин	24.8 мин

Важные ограничения

- Это оценка порядка величины, а не точный таймер.** Разброс времени отдельных запросов большой (R^2 модели ≈ 0.15). Формула даёт типичное «среднее» время, реальный запрос может занять в разы больше/меньше.

2. **Полнотекст — самый чувствительный к объёму.** Для него объём реально ограничивает SLA; для остальных типов объём почти не влияет — главное, чтобы базовое время ($\beta \cdot \delta$) укладывалось в SLA.
3. **Регулярные выражения (RLIKE)** в выборке представлены 2 запросами — её коэффициент ненадёжен, используйте как ориентир.
4. **Глубина < 1 месяца** — доминирующий случай (91% запросов). Для других глубин выборка меньше, поправка δ менее точна.
5. Формула **не включает** фиксированные накладные расходы (запуск задачи, сериализацию), которые в реальных замерах могли присутствовать.

Быстрый ориентир «на глаз»

Ситуация	Примерное время
Обычный поиск (LIKE / равенство), любой объём до ~10 ГБ	~1–2 мин
Полнотекст, до 100 МБ	~10–35 мин
Полнотекст, ~1 ГБ	~1 ч
Полнотекст, 10 ГБ	~1.5–2 ч

Практическое правило: если нужен быстрый ответ и данные большие — избегайте полнотекста (LIKE по всем полям); точечный поиск (по 1–2 полям) выполняется примерно одинаково быстро при любом объёме.